

Gry Szczepionkowe na Sieciach Społecznych

Cena anarchii, teoretyczne i numeryczne ujęcie równowagi Nasha

Stanisław Bochniarz

Streszczenie

Krótkie podsumowanie celów projektu, przyjętego modelu SIR na grafie oraz głównych obserwacji z symulacji.

Spis treści

1	Wstęp i motywacja	3
2	Formalna definicja modelu	4
2.1	Struktura sieci kontaktów	4
2.2	Model epidemiologiczny SIR	5
2.3	Gra szczepionkowa i równowaga	6
3	Epidemia i dynamika gry na grafie	8
3.1	Model SIR na grafie	8
3.2	Przykłady punktów równowagi	9
4	Charakteryzacja równowag na niektórych grafach	14
4.1	Gwiazdy $K_{1,n-1}$	14
4.2	Grafy pełne	17
5	Numeryczne przybliżanie punktów równowagi	21
5.1	Numeryczna weryfikacja profili równowagi	21
6	Fragmenty kodu	23
6.1	Sieć społeczna na grafie oraz symulacja epidemii	23
6.2	Zależności między parametrami w grafach pełnych	26
6.3	Implementacja racjonalnego myślenia agentów	27
	Bibliografia	30

1 Wstęp i motywacja

Jeszcze przed pandemią z 2020 r. pojawiał się temat dzielący społeczeństwo: jak uchronić ludzi przed chorobami zakaźnymi nie odbierając im prawa do dobrowolnych szczepień? W przypadku wielu chorób wieku dziecięcego podstawowym narzędziem ograniczenia ich rozprzestrzeniania jest budowanie odporności zbiorowej. Pojawia się jednak kluczowe pytanie natury teoretycznej: **czy możliwe jest całkowite wyeliminowanie choroby zakaźnej wyłącznie na drodze dobrowolnych decyzji obywateli, bez wprowadzania obligatoryjnego obowiązku szczepień?**

Decyzje o poddaniu dziecka szczepieniu podejmują rodzice, kierując się bilansem zysków i strat (wynikających ze skutków ubocznych zaszczepienia). Z punktu widzenia jednostki wybór ten opiera się na porównaniu dwóch rodzajów ryzyka: postrzeganego ryzyka niepożądanych odczynów poszczepiennych oraz oczekiwanego ryzyka zachorowania i powikłań wynikających z naturalnej infekcji. W ostatnich latach narastającym problemem społecznym stały się tzw. obawy poszczepienne (ang. *vaccine scares*). W ich wyniku część rodziców przypisuje szczepieniom znaczne ryzyko, często skrzywione przez niepewność lub dezinformację.

W tym miejscu ujawnia się subtelny mechanizm teoriogrowy. Gdy poziom zaszczepienia w populacji wzrasta, prawdopodobieństwo napotkania osoby zakaźnej drastycznie maleje. W konsekwencji dla pojedynczej rodziny motywacja do zaszczepienia dziecka zaczyna słabnąć — ryzyko infekcji staje się pomijalnie małe, podczas gdy potencjalne ryzyko poszczepienne (nawet znikome) pozostaje stałe. Prowadzi to do powstania tzw. zjawiska pasażera na gapę (ang. *free-riding*): jednostki czerpią korzyści z odporności populacyjnej wypracowanej przez resztę społeczeństwa, nie ponosząc przy tym bezpośredniego ryzyka zabiegu.

Praca naukowa Bauch i Earna (2004) [1] sformalizowała ten problem matematycznie, wykazując, że w populacji jednorodnie wymieszanej równowaga Nasha uniemożliwia osiągnięcie progu całkowitego usunięcia choroby, jeśli tylko postrzegane ryzyko szczepionki jest większe od zera.

Niniejszy projekt stawia sobie za cel przenieść tę analizę w obszar nowoczesnej matematyki stosowanej i biomatematyki. Badamy w nim, jak klasyczne wnioski teoriogrowe ulegają zmianie, gdy relacje między ludźmi przestają być jednorodne (tak jak w pracy Bauch i Earna), a przybierają strukturę grafów mających odwzorować sieci społeczne. W pracy przeanalizowano procesy decyzyjne agentów, mechanikę rozchodzenia się wirusa na sieci oraz warunki osiągania punktu równowagi Nasha w zależności od geometrii kontaktów społecznych i poziomu postrzeganego ryzyka.

2 Formalna definicja modelu

2.1 Struktura sieci kontaktów

Definicja 2.1 (Stopień wężła i macierz sąsiedztwa). Niech $G = (V, E)$ będzie grafem prostym o $N = |V|$ wierzchołkach.

1. **Macierzą sąsiedztwa** grafu G nazywamy macierz $A = (a_{ij})_{N \times N}$, gdzie $a_{ij} = 1$, gdy $\{i, j\} \in E$, oraz $a_{ij} = 0$ w przeciwnym przypadku.
2. **Stopniem wierzchołka** $i \in V$ nazywamy liczbę jego bezpośrednich sąsiadów, oznaczaną jako:

$$k_i = \sum_{j=1}^N a_{ij}$$

Średni stopień wierzchołka w sieci reprezentujemy jako $\langle k \rangle = \frac{1}{N} \sum_{i=1}^N k_i$.

Struktura kontaktów społecznych rzadko przybiera postać grafu regularnego. W celu odzwierciedlenia rzeczywistych relacji interpersonalnych w symulacjach epidemiologicznych wykorzystuje się generatywne modele grafów losowych.

Definicja 2.2 (Graf losowy Erdősa-Rényiego $G(N, p)$). **Modelem Erdősa-Rényiego** nazywamy zespół grafów losowych o N wierzchołkach, w którym każda z $\binom{N}{2}$ możliwych krawędzi jest tworzona niezależnie z jednakowym prawdopodobieństwem $p \in (0, 1)$.

Rozkład stopni wierzchołków w tym grafie opisuje rozkład dwumianowy, który dla dużych populacji ($N \rightarrow \infty$) przy stałym średnim stopniu $\langle k \rangle = p(N - 1) \approx pN$ dąży do rozkładu Poissona

$$P(k) = \frac{\langle k \rangle^k e^{-\langle k \rangle}}{k!}.$$


Definicja 2.3 (Sieć bezskalowa Barabásiego-Alberta). **Modelem Barabásiego-Alberta** nazywamy dynamiczny graf losowy rozwijany według mechanizmu **preferencyjnego przyłączania** (ang. *preferential attachment*). Konstrukcja grafu przebiega w następujących krokach:

1. **Inicjalizacja:** Startujemy z grafu początkowego o N_0 wierzchołkach.
2. **Wzrost:** W każdym kroku dyskretnym dodawany jest nowy wierzchołek z $m \leq N_0$ nowymi krawędziami.
3. **Preferencyjne przyłączanie:** Prawdopodobieństwo Π_i , że nowo dodany wierzchołek połączy się z istniejącym wierzchołkiem $i \in V$, jest wprost proporcjonalne do aktualnego stopnia k_i tego wierzchołka:

$$\Pi_i = \frac{k_i}{\sum_{j \in V} k_j}.$$

W granicy długich czasów rozkład stopni wierzchołków dąży do rozkładu potęgowego $P(k) \sim k^{-\gamma_{ba}}$ (gdzie dla klasycznego modelu wskaźnik wynosi $\gamma_{ba} = 3$), co prowadzi do powstawania tzw. węzłów-hubów o bardzo wysokim stopniu.

Sposób konstrukcji obu modeli determinuje ich odmienną topologię: model Erdősa-Rényiego, ze względu na niezależność tworzenia połączeń, generuje sieci o charakterze jednorodnym, podczas gdy mechanizm preferencyjnego przyłączania w modelu Barabásiego-Alberta prowadzi do powstania struktury bezskalowej z wyraźnie wyodrębnionymi węzłami o wysokim stopniu (tzw. hubami).



Rysunek 1: Porównanie struktur grafów losowych Erdősa-Rényiego (panel górny) oraz Barabásiego-Alberta (panel dolny) dla różnej liczby węzłów $N \in \{30, 60, 90\}$. W sieciach BA wyrazista jest obecność węzłów centralnych (hubów). Ze względu na jednakowe prawdopodobieństwo połączeń między agentami, model ER znajduje zastosowanie w modelowaniu mikrostruktur (np. lokalnych społeczności), natomiast bezskalowy model BA stosowany jest do reprezentacji wielkoskalowych procesów epidemiologicznych na poziomie populacji krajowych lub kontynentalnych. Skrypt wygenerowany na potrzeby wizualizacji zawarto w Listingu 3.

2.2 Model epidemiologiczny SIR

Aby precyzyjnie zdefiniować mechanizm wyznaczania ryzyka zakażenia $\pi_i(\mathbf{a})$, w niniejszej pracy wykorzystano mikroskopową wersję klasycznego modelu SIR (ang. *Susceptible-Infected-Recovered*) Kermacka i McKendricka, zaadaptowaną do struktur sieciowych.

W dowolnej chwili czasu każdy węzeł grafu $G = (V, E)$ znajduje się w jednym z trzech dyskretnych stanów:

- **S (Podatni):** Osobniki podatne na zakażenie, które nie przyjęły szczepionki i nie miały wcześniej kontaktu z patogenem.
- **I (Zakażeni):** Osobniki aktywnie chorujące, zdolne do zarażania swoich nieuodpornionych sąsiadów w sieci.
- **R (Uodpornieni/Usunięci):** Osobniki, które nie uczestniczą w dalszej transmisji patogenu — wyzdrowiały z nabyciem trwałej odporności lub zostały zaszczepione.

Stochastyczna dynamika rozprzestrzeniania się infekcji opiera się na dwóch procesach:

1. **Transmisja ($S \rightarrow I$):** Jeśli wierzchołek $i \in V$ jest podatny (S), a jego bezpośredni sąsiad $j \in N(i)$ zakażony (I), to przez krawędź $(i, j) \in E$ dochodzi do zarażenia węzła i ze stałą intensywnością (lub prawdopodobieństwem) $\beta \in (0, 1]$.
2. **Wyzdrowienie ($I \rightarrow R$):** Każdy zainfekowany węzeł przechodzi nieodwracalnie do stanu uodpornienia ze stałym współczynnikiem $\gamma > 0$.

Parametr $\gamma > 0$ oznacza **wskaźnik (tempo) wyzdrowienia** agenta w jednostce czasu. Od strony probabilistycznej wyznacza on oczekiwany czas trwania infekcji $\mathbb{E}[T]$. W zależności od sposobu realizacji symulacji parametr ten interpretuje się w następujący sposób:

- **Ujęcie ciągłe (model stochastyczny w czasie ciągłym):** Czas trwania infekcji T jest zmienną losową o rozkładzie wykładniczym z parametrem γ , tzn. $T \sim \text{Exp}(\gamma)$. Wówczas oczekiwany czas chorowania agenta wynosi:

$$\mathbb{E}[T] = \frac{1}{\gamma}$$

- **Ujęcie dyskretne (symulacja krok po kroku):** Parametr $\gamma \in (0, 1]$ reprezentuje prawdopodobieństwo, że zainfekowany gracz (I) w kroku t wyzdrowieje i przejdzie nieodwracalnie do stanu uodpornienia (R) w kroku $t + 1$. W tym przypadku czas trwania choroby opisuje rozkład geometryczny, a średni czas chorowania również wynosi $\mathbb{E}[T] = \frac{1}{\gamma}$ kroków dyskretnych.

W kontekście gry szczepionkowej profil decyzji populacji $\mathbf{a} \in \{0, 1\}^N$ ustala stan początkowy sieci w chwili $t = 0$. Gracze wybierający szczepienie ($a_i = 1$) startują bezpośrednio ze stanu R , tworząc w grafie bariery chroniące sąsiednie węzły. Symulacja epidemii kończy się w momencie wygaszenia ognisk zakażenia ($I = \emptyset$), a zagregowany odsetek symulacji, w których węzeł i uległ infekcji, wyznacza jego empiryczne ryzyko zakażenia $\pi_i(\mathbf{a})$.

2.3 Gra szczepionkowa i równowaga

Definicja 2.4 (Gra szczepionkowa na grafie). Niech $\Gamma = \langle G, A, \mathcal{M}, \pi, u \rangle$ oznacza **dyskretną grę szczepionkową na sieci**, określoną przez piątkę następujących obiektów:

1. $G = (V, E)$ — nieskierowany graf prosty reprezentujący strukturę kontaktów społecznych, gdzie $V = \{1, 2, \dots, N\}$ jest zbiorem graczy (agentów), zaś $E \subseteq V \times V$ zbiorem krawędzi, przez które może zachodzić transmisja patogenu.
2. $A = \prod_{i \in V} A_i$ — przestrzeń profilu strategii całej populacji. Dla każdego gracza $i \in V$ zbiór czystych strategii wynosi $A_i = \{0, 1\}$, gdzie $a_i = 1$ oznacza poddanie się szczepieniu, zaś $a_i = 0$ odmowę szczepienia. Wektor $\mathbf{a} = (a_1, a_2, \dots, a_N) \in A$ oznacza globalny profil decyzji.
3. $\mathcal{M} = (\beta, \gamma, I_0)$ — stochastyczny proces epidemiologiczny (model SIR) rozchodzący się po strukturze G , w którym $\beta \in (0, 1]$ oznacza prawdopodobieństwo transmisji wirusa przez krawędzie $(i, j) \in E$, $\gamma > 0$ jest wskaźnikiem wyzdrowienia, a $I_0 \subset V$ zbiorem węzłów pierwotnie zainfekowanych (pacjentów zero).
4. $\pi = (\pi_1, \pi_2, \dots, \pi_N)$ — operator prawdopodobieństwa zakażenia, w którym funkcja $\pi_i : A \rightarrow [0, 1]$ określa oczekiwane ryzyko zakażenia gracza i przy ustalonym profilu strategii $\mathbf{a}$:

$$\pi_i(\mathbf{a}) = \mathbb{P}(\text{gracz } i \text{ ulegnie infekcji w procesie } \mathcal{M} \mid \mathbf{a}, G)$$

Przy założeniu pełnej skuteczności szczepionki zachodzi $\pi_i(a_i = 1, \mathbf{a}_{-i}) = 0$ dla dowolnego $\mathbf{a}_{-i}$.

5. $u = (u_1, u_2, \dots, u_N)$ — wektor funkcji użyteczności (wyплаты), gdzie wyczekiwana wypłata gracza $i \in V$ dana jest wzorem:

$$u_i(a_i, \mathbf{a}_{-i}) = -r \cdot a_i - \pi_i(a_i, \mathbf{a}_{-i}) \cdot (1 - a_i)$$

gdzie $r = \frac{C_V}{C_I} \in (0, 1)$ określa względne ryzyko szczepienia, stanowiące stosunek postrzeganego kosztu poszczepiennego C_V do oczekiwanego kosztu przechorowania C_I .

Definicja 2.5 (Czysta równowaga Nasha w grze szczepionkowej). Profil strategii $\mathbf{a}^* = (a_1^*, a_2^*, \dots, a_N^*) \in \{0, 1\}^N$ stanowi **czystą równowagę Nasha** w grze $\Gamma = \langle G, A, \mathcal{M}, \pi, u \rangle$, jeśli dla każdego gracza $i \in V$ spełniony jest warunek:

$$\forall i \in V, \quad \forall a_i \in \{0, 1\} : \quad u_i(a_i^*, \mathbf{a}_{-i}^*) \geq u_i(a_i, \mathbf{a}_{-i}^*)$$

gdzie $\mathbf{a}_{-i}^* = (a_1^*, \dots, a_{i-1}^*, a_{i+1}^*, \dots, a_N^*)$ oznacza podprofil decyzji wszystkich graczy z wyjątkiem gracza i .

W kontekście badanej gry szczepionkowej stan równowagi Nasha opisuje sytuację stabilności populacyjnej, w której spełnione są jednocześnie dwa warunki dla każdego agenta $i \in V$:

1. Każdy agent niezaszczepiony ($a_i^* = 0$) szacuje swoje indywidualne ryzyko zakażenia jako nieprzekraczające względnego kosztu szczepionki: $\pi_i(0, \mathbf{a}_{-i}^*) \leq r$.

2. Każdy agent zaszczepiony ($a_i^* = 1$) szacuje, że rezygnacja ze szczepienia naraziłaby go na ryzyko zakażenia co najmniej równe kosztowi szczepionki: $\pi_i(0, \mathbf{a}_{-i}^*) \geq r$.

W konsekwencji równowaga Nasha reprezentuje stan, w którym żaden z graczy nie ma motywacji do jednostronnej zmiany swojej decyzji.

Definicja 2.6 (Dyskretna najlepsza odpowiedź). **Przekształceniem najlepszej odpowiedzi** (ang. *Best Response*) gracza $i \in V$ na dany profil decyzji otoczenia $\mathbf{a}_{-i}$ nazywamy regułą decyzyjną $BR_i(\mathbf{a}_{-i}) \in \{0, 1\}$ określoną jako:

$$BR_i(\mathbf{a}_{-i}) = \arg \max_{a_i \in \{0, 1\}} u_i(a_i, \mathbf{a}_{-i}) = \begin{cases} 1, & \text{jeśli } \pi_i(0, \mathbf{a}_{-i}) > r \\ 0, & \text{jeśli } \pi_i(0, \mathbf{a}_{-i}) \leq r \end{cases}$$

Profil strategii $\mathbf{a}^*$ stanowi czystą równowagę Nasha wtedy i tylko wtedy, gdy dla każdego $i \in V$ zachodzi $a_i^* = BR_i(\mathbf{a}_{-i}^*)$.

Definicja 2.7 (Zjawisko pasażera na gapę / Free-riding). Pasażerem na gapę (ang. *free-rider*) w dyskretniej grze szczepionkowej nazywamy niezaszczepionego gracza $i \in V$ ($a_i = 0$), którego indywidualne ryzyko infekcji $\pi_i(0, \mathbf{a}_{-i})$ spada poniżej względnego kosztu szczepienia r wyłącznie na skutek ochrony epidemiologicznej (tzw. odporności zbiorowej) zapewnianej przez zaszczepionych sąsiadów w sieci.

Agent taki czerpie korzyść w postaci niskiego ryzyka zachorowania, nie ponosząc przy tym indywidualnego kosztu szczepienia C_V .

Definicja 2.8 (Optimum Społeczne i Efektywność Pareto). **Profilem optymalnym społecznie** $\mathbf{a}^{SO} \in \{0, 1\}^N$ nazywamy profil strategii, który maksymalizuje utylitarystyczną sumę wypłat całej populacji:

$$\mathbf{a}^{SO} = \arg \max_{\mathbf{a} \in A} \sum_{i=1}^N u_i(\mathbf{a})$$

Każdy profil optymalny społecznie jest jednocześnie **efektywny w sensie Pareto**.

Definicja 2.9 (Cena anarchii i cena stabilności). Niech $PSNE \subseteq \{0, 1\}^N$ będzie zbiorem czystych równowag Nasha w grze szczepionkowej $\Gamma = \langle G, A, M, \pi, u \rangle$, a

$$W^* = \max_{a \in \{0, 1\}^N} \sum_{i=1}^N u_i(a)$$

sumą wypłat w optimum społecznym (Definicja 2.8). Ponieważ $u_i(a) \leq 0$ dla każdego $i \in V$ oraz $a \in \{0, 1\}^N$, wielkość W^* , jak i suma wypłat w dowolnej równowadze, przyjmują wartości niedodatnie.

Definiujemy **cenę anarchii** (ang. *Price of Anarchy*) jako

$$P_A = \frac{\min_{a \in PSNE} \sum_{i=1}^N u_i(a)}{W^*},$$

oraz **cenę stabilności** (ang. *Price of Stability*) jako

$$P_S = \frac{\max_{a \in PSNE} \sum_{i=1}^N u_i(a)}{W^*}.$$

Z definicji W^* jako maksimum po *wszystkich* profilach strategii wynika, że dla dowolnej równowagi $\mathbf{a}^* \in PSNE$ zachodzi $\sum_i u_i(\mathbf{a}^*) \leq W^*$. Ponieważ obie strony tej nierówności są niedodatnie, dzieląc obustronnie przez $W^* < 0$ (i odwracając kierunek nierówności), otrzymujemy

$$1 \leq P_S \leq P_A,$$

co jest zgodne ze standardową konwencją przyjętą w literaturze (Koutsoupias, Papadimitriou [2]): cena anarchii i cena stabilności są zawsze nie mniejsze niż jeden, przy czym $P_A = 1$ (odpowiednio $P_S = 1$) oznacza, że najgorsza (odpowiednio najlepsza) czysta równowaga Nasha jest jednocześnie optimum społecznym. Różnica $P_A - P_S$ mierzy, jak istotny jest wybór konkretnej równowagi spośród wielu możliwych punktów stabilnych gry Γ .

3 Epidemia i dynamika gry na grafie


Formalna analiza zachowań strategicznych w modelu epidemiologicznym wymaga precyzyjnego zdefiniowania funkcji wypłat oraz reguł decyzyjnych jednostek. W tym rozdziale opisujemy mechanikę gry w szczepieniu na sieciach i przedstawiamy analityczną charakterystykę czystych równowag Nasha (PSNE) dla wybranych klas strukturalnych.

Rozważania teoretyczne koncentrują się na trzech kluczowych aspektach:

- **Struktura wypłat i motywacje graczy:** formalny zapis oczekiwanych kosztów indywidualnych, oparty na bilansie między bezwzględnym kosztem szczepienia C_V a ryzykiem infekcji wynikającym ze struktury połączeń i zjadliwości wirusa τ .
- **Warunki stabilności Nasha:** sformułowanie kryteriów, przy których profil strategii s^* stanowi punkt stały odwzorowania najlepszych odpowiedzi (*Best-Response*), wykluczający opłacalność jednostronnych odchyień.
- **Charakterystyka topologiczna:** wyznaczenie ścisłych warunków istnienia oraz postaci równowag dla skrajnych układów sieciowych — od idealnej symetrii (grafy pełne K_n), przez skrajną asymetrię (gwiazdy $K_{1,n-1}$), po liniową propagację przestrzenną (ścieżki P_n i cykle C_n).

3.1 Model SIR na grafie

Warunkiem koniecznym do prawidłowej operacjonalizacji dyskretnego modelu epidemiologicznego jest zdefiniowanie parametrów stochastycznych $\beta, \gamma \in (0, 1]$. Parametr β określa prawdopodobieństwo transmisji patogenu w pojedynczym dyskretnym kroku czasowym t pomiędzy parą połączonych krawędzią węzłów: zakażonym i podatnym. Z kolei parametr γ reprezentuje prawdopodobieństwo wyzdrowienia zainfekowanego agenta w danym kroku symulacyjnym. W konsekwencji czas trwania infekcji jest zmienną losową o rozkładzie geometrycznym z parametrem γ , co wyznacza oczekiwaną długość trwania choroby równą $\mathbb{E}[T] = \frac{1}{\gamma}$. Implementację modelu w języku Python przedstawiono w Listingu 4. Symulacja z wyżej wymienionego Listingu rozpoczęła się od grafu przedstawionego na poniższym rysunku.



Rysunek 2: Stan początkowy sieci kontaktów w grze szczepionkowej ($t = 0$) przy podanym profilu strategii. Kolorem niebieskim oznaczono węzły podatne (S), czerwonym zakażone (I), zaś zielonym uodpornione/zaszczepione (R).

Przyjęte parametry to $\beta = \frac{1}{3}$ oraz $\gamma = \frac{1}{2}$. Wyniki przebiegu stochastycznego procesu SIR dla wygenerowanej sieci przedstawiają się następująco:


```

1 Krok t = 1 | S: 16 | I: 1 | R: 13 | Nowe infekcje: 0 | Wyzdrowieli: 0
2 Krok t = 2 | S: 16 | I: 1 | R: 13 | Nowe infekcje: 0 | Wyzdrowieli: 0
3 Krok t = 3 | S: 12 | I: 4 | R: 14 | Nowe infekcje: 4 | Wyzdrowieli: 1
4 Krok t = 4 | S: 8 | I: 7 | R: 15 | Nowe infekcje: 4 | Wyzdrowieli: 1
5 Krok t = 5 | S: 7 | I: 3 | R: 20 | Nowe infekcje: 1 | Wyzdrowieli: 5
6 Krok t = 6 | S: 6 | I: 2 | R: 22 | Nowe infekcje: 1 | Wyzdrowieli: 2
7 Krok t = 7 | S: 5 | I: 2 | R: 23 | Nowe infekcje: 1 | Wyzdrowieli: 1
8 Krok t = 8 | S: 5 | I: 0 | R: 25 | Nowe infekcje: 0 | Wyzdrowieli: 2

```

Listing 1: Przebieg przykładowej symulacji epidemii SIR w kolejnych krokach czasowych

Stan sieci po całkowitym wygaszeniu ogniska zakażeń ($I = \emptyset$) w kroku $t = 8$ zaprezentowano na Rysunku 3.



Rysunek 3: Końcowy stan sieci po 8 krokach symulacji i wygaszeniu transmisji wirusa.

Z zaprezentowanej realizacji wynika kluczowa obserwacja merytoryczna: brak decyzji o szczepieniu ($a_i = 0$) nie jest tożsamy z koniecznością zachorowania. Część niezaszczepionych agentów zachowuje stan podatności (S) do samego końca epidemii. Zjawisko to wynika z osłony epidemiologicznej zapewnianej przez uodpornione sąsiedztwo, co stanowi bezpośrednią empiryczną ilustrację mechanizmu pasażera na gapę. Kod programu wykorzystanego do przeprowadzenia symulacji można znaleźć pod Listingiem 5.

3.2 Przykłady punktów równowagi

Strukturę punktów równowagi w rozważanym modelu przedstawiono najpierw na przykładzie podstawowych układów sieciowych, dla których możliwe jest ścisłe wyznaczenie prawdopodobieństw zakażenia π_i .

Przykład 1. Przyjęcie założenia, że pacjent zero jest wybierany wyłącznie spośród graczy niezaszczepionych ($a_j = 0$), istotnie wpływa na strukturę równowag Nasha. W szczególności profil strategii, w którym wszyscy gracze decydują się na szczepienie ($\mathbf{a} = \mathbf{1}$), stanowi w tym modelu czystą równowagę Nasha.

Rozważmy jednostronne odstępstwo i -tego agenta od strategii $\mathbf{a} = \mathbf{1}$. Jeśli agent i zmieni decyzję na $a_i = 0$, stanie się jedynym niezaszczepionym graczem w sieci, co deterministycznie czyni go pacjentem zero ($\pi_i(0, \mathbf{a}_{-i}) = 1$). Porównanie wypłat agenta dla obu strategii przedstawia się następująco:

$$\begin{aligned}
 u_i(1, \mathbf{a}_{-i}) &= -r \cdot 1 - \pi_i(1, \mathbf{a}_{-i}) \cdot (1 - 1) = -r, \\
 u_i(0, \mathbf{a}_{-i}) &= -r \cdot 0 - 1 \cdot (1 - 0) = -1.
 \end{aligned}$$


Zakładając, że koszt szczepienia spełnia warunek $r \in (0, 1)$, zachodzi relacja $-r > -1$, czyli $u_i(1, \mathbf{a}_{-i}) > u_i(0, \mathbf{a}_{-i})$.

Wynik ten jest w pełni spójny z przekształceniem najlepszej odpowiedzi (Definicja 2.6):

$$BR_i(\mathbf{a}_{-i}) = \arg \max_{a_i \in \{0, 1\}} u_i(a_i, \mathbf{a}_{-i}) = \begin{cases} 1, & \text{jeśli } \pi_i(0, \mathbf{a}_{-i}) > r, \\ 0, & \text{jeśli } \pi_i(0, \mathbf{a}_{-i}) \leq r. \end{cases}$$

Ponieważ $\pi_i(0, \mathbf{a}_{-i}) = 1 > r$, najlepszą odpowiedzią gracza i pozostaje $a_i = 1$. Żaden z agentów nie ma zatem motywacji do jednostronnej zmiany strategii, co potwierdza, że profil $\mathbf{a} = \mathbf{1}$ tworzy punkt równowagi. $\square$

Przykład 2. Rozpatrzmy grę szczepionkową na grafie $K_{1,3}$ z parametrami $\beta = \gamma = r = \frac{1}{2}$ oraz profil strategii $\mathbf{a} = (0, 0, 0, 1)$ (Rysunek 4).



Rysunek 4: Profil strategii $\mathbf{a} = (0, 0, 0, 1)$ na grafie gwiazdy $K_{1,3}$. Zaszczepiony agent 4 (R) tworzy barierę ochronną dla niezaszczepionych liści 1, 2 i 3 (S).

Wykażemy, że profil $\mathbf{a}$ stanowi czystą równowagę Nasha:

1. **Gracze $i \in \{1, 2, 3\}$ (liście):** Zaszczepiony węzeł centralny ($a_4 = 1$) stanowi barierę izolującą od siebie liście. Każdy z liści może ulec zakażeniu wyłącznie wtedy, gdy sam zostanie wyznaczony jako pacjent zero. Przy losowaniu pacjenta zero spośród niezaszczepionych graczy $\{1, 2, 3\}$ mamy:

$$\pi_i(0, \mathbf{a}_{-i}) = \frac{1}{3} \leq r = \frac{1}{2} \implies BR_i(\mathbf{a}_{-i}) = 0.$$

Żaden z graczy 1, 2, 3 nie ma motywacji do zmiany strategii na szczepienie.

2. **Gracz 4 (centrum):** Sprawdzamy opłacalność odstępstwa od szczepienia ($a_4 = 0$). Całkowite ryzyko zakażenia agenta 4 wynosi:

$$\pi_4(0, \mathbf{a}_{-4}) = \mathbb{P}(I_0 = 4) \cdot 1 + \mathbb{P}(I_0 \neq 4) \cdot \mathbb{P}(\text{Gr. 4 zachoruje} \mid I_0 \neq 4).$$

Prawdopodobieństwo braku zakażenia od zainfekowanego sąsiada wyznaczamy, warunkując po czasie choroby pacjenta zero $T \sim \text{Geom}(\gamma)$:

$$\mathbb{P}(\text{Gr. 4 nie zachoruje} \mid I_0 \neq 4) = \sum_{k=1}^{\infty} (1 - \beta)^k (1 - \gamma)^{k-1} \gamma = \sum_{k=1}^{\infty} \left(\frac{1}{4}\right)^k = \frac{1}{3}.$$

Stąd $\mathbb{P}(\text{Gr. 4 zachoruje} \mid I_0 \neq 4) = 1 - \frac{1}{3} = \frac{2}{3}$, co daje pełne ryzyko:


$$\pi_4(0, \mathbf{a}_{-4}) = \frac{1}{4} \cdot 1 + \frac{3}{4} \cdot \frac{2}{3} = \frac{3}{4}.$$

Ponieważ $\pi_4(0, \mathbf{a}_{-4}) = \frac{3}{4} > r = \frac{1}{2}$, najlepszą odpowiedzią gracza 4 jest $BR_4(\mathbf{a}_{-4}) = 1$.

Każdy z graczy realizuje swoją najlepszą odpowiedź ($a_i = BR_i(\mathbf{a}_{-i})$), co dowodzi, że profil $\mathbf{a} = (0, 0, 0, 1)$ jest czystą równowagą Nasha. $\square$

Powyższa równowaga idealnie ilustruje zjawisko *pasażera na gapę* (ang. *free-riding*) na sieciach. Węzeł centralny (gracz 4), ze względu na wysoki stopień połączeń, jest zmuszony ponieść koszt szczepienia (r), aby uniknąć wysokiego ryzyka zakażenia ($\pi_4 = \frac{3}{4} > r$). Jego decyzja tworzy jednak barierę ochronną dla całej sieci. Gracze obwodowi (1, 2, 3) czerpią z tej bariery bezpośrednią korzyść — ich ryzyko zakażenia spada poniżej progu opłacalności szczepienia ($\pi_i = \frac{1}{3} \leq r$). W efekcie zachowują oni stan podatności ($a_i = 0$) i nie ponoszą żadnych kosztów, korzystając z ochrony wygenerowanej wyłącznie przez agenta centralnego.

Przykład 3. Rozpatrzmy grę szczepionkową na grafie diamentowym $K_4 \setminus \{e\}$ z parametrami $\beta = \gamma = r = \frac{1}{2}$ oraz profil strategii $\mathbf{a} = (1, 0, 1, 0)$, w którym gracze centralni na przekątnej są zaszczerpieni ($a_1 = 1, a_3 = 1$), a gracze obwodowi pozostają niezaszczerpieni ($a_2 = 0, a_4 = 0$) (Rysunek 5).



Rysunek 5: Profil strategii $\mathbf{a} = (1, 0, 1, 0)$ na grafie diamentowym. Zaszczepieni gracze 1 i 3 (R) izolują od siebie obwodowych graczy 2 i 4 (S).

Wykażemy, że profil **a** stanowi czystą równowagę Nasha:

1. **Gracze obwodowi** $i \in \{2, 4\}$: Dla gracza 2 ($a_2 = 0$) zbiór agentów niezaszczepionych wynosi $\{2, 4\}$. Pacjent zero jest losowany spośród nich z prawdopodobieństwem $\frac{1}{2}$. Jeśli $I_0 = 4$, wirus zostaje uwieczony w węźle 4, ponieważ jego jedyni sąsiedzi (1 i 3) są zaszczepieni (R). Stąd ryzyko zakażenia wynosi:

$$\pi_2(0, \mathbf{a}_{-2}) = \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 0 = \frac{1}{2}.$$

Ponieważ $\pi_2(0, \mathbf{a}_{-2}) = \frac{1}{2} \leq r = \frac{1}{2}$, gracz 2 nie ma motywacji do zmiany strategii ($BR_2(\mathbf{a}_{-2}) = 0$). Z symetrii to samo zachodzi dla gracza 4 ($BR_4(\mathbf{a}_{-4}) = 0$).

2. **Gracze centralni** $i \in \{1, 3\}$: Sprawdzamy opłacalność jednostronnego odstępowania gracza 1 od szczytowania ($a_1 = 0$). Przy zespole niezaszczepionych $\{1, 2, 4\}$ pacjent zero jest losowany z prawdopodobieństwem $\frac{1}{3}$. W przypadku wyznaczenia sąsiada jako ogniska zakażenia ($I_0 \in \{2, 4\}$), transmisja do gracza 1 zachodzi z prawdopodobieństwem $p_{\text{trans}} = \frac{2}{3}$. Całkowite ryzyko wynosi:

$$\pi_1(0, \mathbf{a}_{-1}) = \frac{1}{3} \cdot 1 + \frac{1}{3} \cdot \frac{2}{3} + \frac{1}{3} \cdot \frac{2}{3} = \frac{7}{9}.$$

Ponieważ $\pi_1(0, \mathbf{a}_{-1}) = \frac{7}{9} > r = \frac{1}{2}$, najlepszą odpowiedzią gracza 1 pozostaje szczepienie ($BR_1(\mathbf{a}_{-1}) = 1$). Z symetrii analogiczny wynik otrzymujemy dla gracza 3 ($BR_3(\mathbf{a}_{-3}) = 1$).

Każdy gracz realizuje swoją najlepszą odpowiedź ($a_i = BR_i(\mathbf{a}_{-i})$), co potwierdza, że profil $\mathbf{a} = (1, 0, 1, 0)$ tworzy czystą równowagę Nasha. $\square$

Obserwacja: Przedstawione przykłady ujawniają ogólną intuicję dotyczącą topologii czystych równowag Nasha: agent niezaszczepiony ($a_i = 0$) może trwale utrzymać swoją strategię wtedy, gdy jego bezpośrednie sąsiedztwo lub ścieżki krytyczne w sieci są zabezpieczone przez graczy zaszczepionych ($a_j = 1$). W efekcie w stanach równowagi zbiór węzłów niezaszczepionych ma tendencję do tworzenia *zbioru niezależnego* (lub podgrafu o zredukowanej spójności), w którym koszt ochrony całej populacji przejmowany jest przez węzły o wyższym stopniu połączeń lub kluczowym położeniu w topologii grafu. Intuicja ta nie jest jednak w żaden sposób ogólną regułą ani prawem, poniżej wskażemy kontrprzykład lecz najpierw dla wygody uzasadnienia udowodnimy prostu lemat.

Lemat 1 (Prawdopodobieństwo transmisji na krawędzi). Niech $\beta \in (0, 1]$ oznacza prawdopodobieństwo infekcji podatnego węzła przez zainfekowanego sąsiada w pojedynczym kroku czasowym, a $\gamma \in (0, 1]$ oznacza prawdopodobieństwo wyzdrowienia w tym samym kroku. Wówczas całkowite prawdopodobieństwo p_{trans} , że zainfekowany gracz skutecznie zarazi swojego podatnego sąsiada przed własnym wyzdrowieniem, wynosi:

$$p_{\text{trans}} = \frac{\beta}{\beta + \gamma - \beta\gamma}.$$

Dowód. Rozważmy przebieg pojedynczej tury t dla zainfekowanego agenta u oraz jego podatnego sąsiada v . W każdym kroku czasowym zachodzi jedna z wykluczających się ścieżek:

1. Z prawdopodobieństwem β następuje skuteczna transmisja wirusa z u do v .
2. Z prawdopodobieństwem $1 - \beta$ do transmisji nie dochodzi. Wówczas:
 - z prawdopodobieństwem γ agent u wyzdrowieje, co kończy proces brakiem infekcji agenta v ,
 - z prawdopodobieństwem $1 - \gamma$ agent u pozostaje zainfekowany i w kolejnej turze $t + 1$ proces powtarza się na identycznych warunkach.

Wykorzystując wzór na prawdopodobieństwo całkowite oraz bezpamięciowość dyskretnego procesu, zapisujemy równanie rekurencyjne na p_{trans} :

$$p_{\text{trans}} = \beta + (1 - \beta)(1 - \gamma)p_{\text{trans}}.$$

Przekształcając równanie algebraicznie względem p_{trans} :

$$\begin{aligned} p_{\text{trans}} - (1 - \beta)(1 - \gamma)p_{\text{trans}} &= \beta, \\ p_{\text{trans}} [1 - (1 - \beta - \gamma + \beta\gamma)] &= \beta, \\ p_{\text{trans}} (\beta + \gamma - \beta\gamma) &= \beta. \end{aligned}$$

Ponieważ dla $\beta, \gamma \in (0, 1]$ mianownik $\beta + \gamma - \beta\gamma$ jest ściśle dodatni, dzieląc przez niego obustronnie, otrzymujemy tezę lematu:

$$p_{\text{trans}} = \frac{\beta}{\beta + \gamma - \beta\gamma}.$$

$\square$


Przykład 4. Rozpatrzmy profil strategii $\mathbf{a} = (1, 1, 1, 1, 0, 0, 0)$ na grafie złożonym z cyklu $C_4 = (1, 2, 3, 4)$ oraz trzech liści połączonych odpowiednio z węzłami 1, 2 i 3 (Rysunek 6). Przyjmujemy parametry $\beta = \gamma = r = \frac{1}{2}$ ($p_{\text{trans}} = \frac{2}{3}$). Zbiór graczy zaszczepionych wynosi $R = \{1, 2, 3, 4\}$, a niezaszczepionych $S = \{5, 6, 7\}$.

Wykażemy, że rozważany profil **nie stanowi** równowagi Nasha:

Rozpatrzmy motywację gracza 4 ($a_4 = 1$) do zmiany strategii na brak szczepienia ($a_4 = 0$). Gdyby gracz 4 powstrzymał się od szczepienia, nowy zbiór niezaszczepionych powiększyłby się do $S' = \{4, 5, 6, 7\}$.

Duża liczba graczy niezaszczepionych w sieci ($|S| = 3$) działa na korzyść gracza 4, istotnie zmniejszając jego ryzyko zostania pacjentem zero — szansa wyznaczenia go jako ogniska choroby spada do:

$$\mathbb{P}(I_0 = 4) = \frac{1}{|S'|} = \frac{1}{4}.$$



Rysunek 6: Profil strategii $\mathbf{a} = (1, 1, 1, 1, 0, 0, 0)$. Węzeł 4 jest w pełni otoczony przez zaszczepionych sąsiadów (1 i 3), co czyni jego własne szczepienie nadmiarowym.

Jednocześnie gracz 4 jest dalej otoczony dwoma zaszczepionymi sąsiadami (węzły 1 i 3), co całkowicie blokuje transmisję wirusa z reszty sieci. Całkowite ryzyko zachorowania dla gracza 4 po zmodyfikowaniu strategii wynosi zatem:

$$\pi_4(0, \mathbf{a}_{-4}) = \frac{1}{4} \cdot 1 + \frac{3}{4} \cdot 0 = \frac{1}{4}.$$

Ponieważ ryzyko zakażenia po zmianie strategii jest ściśle niższe niż koszt szczepienia ($\pi_4(0, \mathbf{a}_{-4}) = \frac{1}{4} < r = \frac{1}{2}$), najlepszą odpowiedzią gracza 4 jest porzucenie szczepienia ($BR_4(\mathbf{a}_{-4}) = 0$).

Gracz 4 odnosi bezpośrednią korzyść ze jednostronnego odstąpienia ($a_4 \neq BR_4(\mathbf{a}_{-4})$), co dowodzi, że dany profil nie tworzy równowagi Nasha. $\square$

4 Charakteryzacja równowag na niektórych grafach

W tym rozdziale wyznaczamy analitycznie czyste równowagi Nasha dla wybranych klas grafów: grafów pełnych K_n , gwiazd $K_{1,n-1}$ oraz ścieżek P_n i cykli C_n . Analiza tych kanonicznych struktur pozwala zrozumieć wpływ symetrii, obecności hubów oraz geometrii sieci na decyzje strategiczne graczy.

4.1 Gwiazdy $K_{1,n-1}$

Topologia gwiazdy $K_{1,n-1}$ stanowi skrajną, ascetyczną reprezentację węzłów o bardzo wysokiej konektywności (tzw. hubów), stanowiących fundament sieci bezskalowych generowanych m.in. przez model Barabásiego–Alberta. Graf ten składa się z jednego węzła centralnego o stopniu $n-1$ oraz $n-1$ liści o stopniu 1. Ze względu na całkowity brak bezpośrednich krawędzi między liśćmi, jakkolwiek transmisja patogenu w populacji musi przebiegać przez centrum. Z punktu widzenia teorii gier tworzy to głęboką asymetrię strategiczną: decyzja huba o poddaniu się szczepieniu działa jak funkcjonalna izolacja pozostałych graczy, radykalnie redukując ich indywidualne ryzyko infekcji i wyznaczając specyficzny układ równowagi Nasha. Zakładamy tutaj dla uproszczenia $n \geq 4$, aby omawiane grafy nie miały topologii ścieżki P_n , oraz że węzeł centralny jest graczem pierwszym.

Przykład 5. Rozpatrzmy profil strategii

$$a^* = (1, 0, \dots, 0).$$

Wektor prawdopodobieństw łatwo można znaleźć, rozpatrując przypadki odchyień:

$$\pi_1(0, a_{-1}^*) = \frac{1}{n} + \frac{n-1}{n} \cdot p_{\text{trans}}$$

oraz

$$\pi_i(0, a_{-i}^*) = \frac{1}{n-1}, \quad i = 2, 3, \dots, n.$$

Nietrudno więc sprawdzić, że profil a^* stanowi czystą równowagę Nasha, jeśli parametry spełniają układ nierówności:

$$\begin{cases} \frac{1}{n} + \frac{n-1}{n} \cdot p_{\text{trans}} > r, \\ \frac{1}{n-1} < r. \end{cases} \quad (1)$$

Taką równowagę dla $n = 4$ przedstawiono w Przykładzie 2. □

Przykład 6. Rozważmy alternatywny profil strategii $a^0 = (0, 0, \dots, 0)$, w którym żaden z graczy się nie szczepi. Pula niezaszczepionych wynosi n . Ryzyko infekcji dla huba wynosi wówczas:

$$\pi_1(a^0) = \frac{1}{n} + \frac{n-1}{n} \cdot p_{\text{trans}},$$

natomiast dla dowolnego liścia $i \geq 2$:

$$\pi_i(a^0) = \frac{1}{n} + \frac{1}{n} \cdot p_{\text{trans}} + \frac{n-2}{n} \cdot p_{\text{trans}}^2.$$

Ponieważ $\pi_1(a^0) > \pi_i(a^0)$, hub jest najbardziej podatny na zakażenie. Profil a^0 stanowi czystą równowagę Nasha wtedy i tylko wtedy, gdy hubowi nie opłaca się jednostronnie zaszczepić, czyli:

$$\frac{1}{n} + \frac{n-1}{n} \cdot p_{\text{trans}} \leq r.$$

Nierówność ta wyznacza próg akceptacji ryzyka, poniżej którego populacja pozostaje całkowicie niezaszczepiona. □

Lemat 2 (Ograniczenie przestrzeni poszukiwań optimum społecznego). Dla gry szczepionkowej na grafie gwiazdy $K_{1,n-1}$ z $n \geq 4$, dowolny profil strategii $a \notin \{a^*, a^0, a^{\text{all}}\}$, gdzie

$$a^* = (1, 0, \dots, 0), \quad a^0 = (0, \dots, 0), \quad a^{\text{all}} = (1, \dots, 1)$$

jest ściśle zdominowany pod względem kosztu społecznego $SC(a)$ przez profil a^* . W konsekwencji profil realizujący optimum społeczne

$$a^{\text{SO}} = \arg \min_{a \in A} SC(a) = \arg \max_{a \in A} \sum_{i=1}^n u_i(a)$$

należy do zbioru profili brzegowych:

$$a^{\text{SO}} \in \{a^*, a^0, a^{\text{all}}\}.$$

Dowód. Niech $a = (a_1, a_2, \dots, a_n) \in \{0, 1\}^n$ oznacza dowolny profil strategii, gdzie $a_1 \in \{0, 1\}$ jest decyzją huba, a $k = \sum_{i=2}^n a_i$ określa liczbę zaszczepionych liści. Całkowity koszt społeczny ma postać:

$$SC(a) = - \sum_{i=1}^n u_i(a) = (a_1 + k)r + \mathbb{E}[\text{liczba zakażonych} \mid a]. \quad (2)$$

Rozpatrzmy dwa dopełniające przypadki dla profili pośrednich $a \notin \{a^*, a^0, a^{\text{all}}\}$:

1. **Przypadek** $a_1 = 1$ **oraz** $1 \leq k < n - 1$: Zaszczepiony hub całkowicie blokuje transmisję patogenu w grafie. Ponieważ Pacjent Zero jest losowany spośród $n - 1 - k$ niezaszczepionych liści, infekcji ulega wyłącznie ten jeden wylosowany gracz. Oczekiwana liczba zakażonych wynosi zatem dokładnie 1. Koszt społeczny wynosi:

$$SC(a) = (1 + k)r + 1.$$

Ponieważ $k \geq 1$ oraz $r > 0$, zachodzi:

$$SC(a) = (1 + k)r + 1 > r + 1 = SC(a^*).$$

2. **Przypadek** $a_1 = 0$ **oraz** $1 \leq k \leq n - 1$: Hub pozostaje niezaszczepiony, zatem w sieci występuje transmisja patogenu. Ponieważ co najmniej jeden gracz ulega zakażeniu (Pacjent Zero), oczekiwana liczba zakażonych wynosi co najmniej 1, przy czym dla $k < n - 1$ jest ściśle większa od 1.

- Dla $k = 1$: $SC(a) = r + \mathbb{E}[\text{zakażenia}] > r + 1 = SC(a^*)$.
- Dla $k > 1$: $SC(a) = k \cdot r + \mathbb{E}[\text{zakażenia}] \geq k \cdot r + 1 > r + 1 = SC(a^*)$.

W obu przypadkach każdy profil pośredni generuje koszt społeczny ściśle większy niż $SC(a^*)$, co kończy dowód. $\square$

Lemat 3 (Zawężenie zbioru równowag Nasha na gwiazdzie $K_{1,n-1}$). Dla gry szczepionkowej na grafie gwiazdy $K_{1,n-1}$ ($n \geq 4$) z losowaniem Pacjenta Zero wyłącznie spośród osób niezaszczepionych, zbiór czystych równowag Nasha spełnia inkluzję:

$$PSNE \subseteq \{a^*, a^0, a^{\text{all}}\},$$

gdzie $a^* = (1, 0, \dots, 0)$, $a^0 = (0, 0, \dots, 0)$ oraz $a^{\text{all}} = (1, 1, \dots, 1)$.

Dowód. Niech $k = \sum_{i=2}^n a_i$ oznacza liczbę zaszczepionych liści. Wykażemy, że żaden profil pośredni $a \notin \{a^*, a^0, a^{\text{all}}\}$ nie tworzy czystej równowagi Nasha, rozpatrując decyzję huba $a_1 \in \{0, 1\}$:

1. **Przypadek** $a_1 = 1$ **oraz** $1 \leq k < n - 1$: Hub jest zaszczepiony, więc transmisja w sieci jest całkowicie zablokowana.
 - Dla zaszczepionego liścia i ($a_i = 1$): przy odstąpieniu od szczepienia liczba niezaszczepionych graczy rośnie do $n - k$. Zachoruje on tylko jako Pacjent Zero z prawdopodobieństwem $\frac{1}{n-k}$. Warunek braku odchylenia: $r \leq \frac{1}{n-k}$.

- Dla niezaszczepionego liścia j ($a_j = 0$): jego obecne ryzyko wynosi $\frac{1}{n-1-k}$. Warunek braku odchylenia: $r \geq \frac{1}{n-1-k}$.

Otrzymujemy podwójną nierówność $\frac{1}{n-1-k} \leq r \leq \frac{1}{n-k}$. Ponieważ $n-1-k < n-k$, zachodzi $\frac{1}{n-1-k} > \frac{1}{n-k}$, co stanowi sprzeczność.

2. **Przypadek $a_1 = 0$ oraz $1 \leq k \leq n-1$:** Hub nie jest zaszczepiony, więc pośredniczy w transmisji patogenu. Niech $m = n-k \geq 1$ oznacza liczbę niezaszczepionych graczy.

- Aby niezaszczepiony hub nie chciał się zaszczepić, koszt r musi przewyższać jego ryzyko infekcji:

$$r \geq \pi_1(a) = \frac{1 + (m-1)p_{\text{trans}}}{m}.$$

- Aby zaszczepiony liść i ($a_i = 1$) nie chciał zrezygnować ze szczepienia, koszt r nie może przewyższać jego ryzyka po odchyleniu:

$$r \leq \pi_i(0, a_{-i}) = \frac{1 + p_{\text{trans}} + (m-1)p_{\text{trans}}^2}{m+1}.$$

Nietrudno wykazać, że dla każdego $p_{\text{trans}} \in [0, 1)$ zachodzi $\pi_1(a) > \pi_i(0, a_{-i})$, co prowadzi do sprzeczności $r \geq \pi_1(a) > \pi_i(0, a_{-i}) \geq r$.

W konsekwencji żaden profil pośredni nie spełnia warunków równowagi Nasha, zatem

$$PSNE \subseteq \{a^*, a^0, a^{\text{all}}\}.$$

□

Korzystając ze wzoru 2 łatwo przekonać się, że

$$SC(a^*) = r + 1, \quad SC(a^{\text{all}}) = r$$

natomiast

$$SC(a^0) = \mathbb{E}[\text{liczba zakażonych} \mid a^0].$$

Wyznaczamy wartość oczekiwaną poprzez rozbięcie na rozłączne zdarzenia wyboru Pacjenta Zero $I_0 \in \{1, \dots, n\}$, gdzie $\mathbb{P}(I_0 = k) = \frac{1}{n}$ dla każdego k :

1. **Pacjentem Zero jest hub** ($I_0 = 1$): Zakażeniu ulega hub oraz każdy z $n-1$ liści niezależnie z prawdopodobieństwem p_{trans} :

$$\mathbb{E}[\text{zakażeni} \mid I_0 = 1] = 1 + (n-1)p_{\text{trans}}.$$

2. **Pacjentem Zero jest jeden z liści** ($I_0 \geq 2$): Zakażeniu ulega ten liść (1), hub z prawdopodobieństwem p_{trans} , a każdy z pozostałych $n-2$ liści z prawdopodobieństwem p_{trans}^2 (transmisja dwuetapowa przez hub):

$$\mathbb{E}[\text{zakażeni} \mid I_0 \geq 2] = 1 + p_{\text{trans}} + (n-2)p_{\text{trans}}^2.$$

Korzystając ze wzoru na prawdopodobieństwo całkowite dla $\mathbb{P}(I_0 = 1) = \frac{1}{n}$ oraz $\mathbb{P}(I_0 \geq 2) = \frac{n-1}{n}$:

$$\begin{aligned} \mathbb{E}[\text{zakażeni} \mid a^0] &= \frac{1}{n} [1 + (n-1)p_{\text{trans}}] + \frac{n-1}{n} [1 + p_{\text{trans}} + (n-2)p_{\text{trans}}^2] \\ &= \frac{1 + (n-1)p_{\text{trans}} + (n-1) + (n-1)p_{\text{trans}} + (n-1)(n-2)p_{\text{trans}}^2}{n} \\ &= \frac{n + 2(n-1)p_{\text{trans}} + (n-1)(n-2)p_{\text{trans}}^2}{n} \\ &= 1 + \frac{n-1}{n} p_{\text{trans}} (2 + (n-2)p_{\text{trans}}). \end{aligned}$$

■

4.2 Grafy pełne

Graf pełny K_l reprezentuje populację idealnie wymieszaną i stanowi dyskretny odpowiednik klasycznego modelu Baucha i Earna. Ze względu na pełną symetrię struktury, prawdopodobieństwo infekcji niezaszczepionego agenta zależy wyłącznie od łącznej liczby niezaszczepionych graczy n . Ponieważ szczepienie w rozważanym modelu zapewnia pełną odporność na chorobę, ograniczenie obszaru analizy do podgrafu K_n złożonego wyłącznie z niezaszczepionych węzłów jest w pełni uzasadnione.

Definicja 4.1. Rozpatrzmy graf pełny K_n z profilem strategii, w którym żaden z agentów się nie szczepi. Niech Z będzie zmienną losową określającą liczbę agentów bezpośrednio zainfekowanych przez losowo wybranego pacjenta zero (przyjmijmy bez utraty ogólności, że jest to gracz 1). *Bazowym współczynnikiem reprodukcji* nazywamy wartość oczekiwaną:

$$R_0 = \mathbb{E}(Z).$$

Lemat 4. Przy założeniach z powyższej definicji zachodzi równość:

$$R_0 = (n - 1)p_{\text{trans}}.$$

Dowód. Niech X_i oznacza zmienną wskaźnikową zakażenia bezpośredniego:

$$X_i = \begin{cases} 1, & \text{jeśli gracz } i \text{ został zakażony bezpośrednio przez pacjenta zero,} \\ 0, & \text{w przeciwnym przypadku.} \end{cases}$$


Liczba bezpośrednich zakażeń wynosi $Z = \sum_{i=2}^n X_i$. Z liniowości wartości oczekiwanej oraz pełnej symetrii węzłów otrzymujemy:

$$\mathbb{E}(Z) = \sum_{i=2}^n \mathbb{E}(X_i) = (n - 1)\mathbb{P}(X_2 = 1) = (n - 1)p_{\text{trans}}.$$

□

Profile równowagi Nasha są ściśle powiązane z indywidualnym ryzykiem zachorowania agenta, oznaczanym jako $\pi(n)$. Analityczne wyznaczenie jawnej postaci tego ryzyka w zależności od liczby graczy n oraz parametrów epidemiologicznych charakteryzuje się wysoką złożonością kombinatoryczną. Z tego względu zastosowano metodę symulacji Monte Carlo w celu oszacowania wartości parametru $\pi(n)$ dla różnych zestawów (n, R_0) .

Zgodnie z przewidywaniami teoretycznymi, dla $R_0 < 1$ indywidualne ryzyko infekcji asymptotycznie zmierza do zera wraz ze wzrostem n , podczas gdy dla $R_0 > 1$ stabilizuje się na dodatnim poziomie. Na rysunku 7 zaprezentowano wyniki symulacji przeprowadzonej według procedury opisanej w Listingu 6.



Rysunek 7: Indywidualne ryzyko zachorowania $\pi(n)$ w funkcji liczby niezaszczepionych graczy n dla wybranych wartości R_0 .

Twierdzenie 4.1. Niech $\pi_n(R_0)$ oznacza prawdopodobieństwo, że dowolnie wybrany niezaszczepiony wierzchołek zostanie zainfekowany przy ustalonym $R_0 > 0$, oraz niech $\pi_\infty(R_0) = \lim_{n \rightarrow \infty} \pi_n(R_0)$. Wówczas:

$$\pi_\infty(R_0) = 0 \quad \text{dla } R_0 < 1.$$

Dowód. Niech X^n oznacza łączną liczbę zainfekowanych agentów (wraz z Pacjentem Zero) w trakcie całego trwania epidemii:

$$X^n = \sum_{t=0}^{\infty} Z_t,$$

gdzie Z_t oznacza liczbę nowo zainfekowanych agentów w fali t . Indywidualne ryzyko zachorowania wyraża się wzorem:

$$\pi_n(R_0) = \frac{\mathbb{E}(X^n) - 1}{n - 1}.$$

Z definicji stanu początkowego $Z_0 = 1$, skąd $\mathbb{E}(Z_0) = 1$, a dla pierwszej fali $\mathbb{E}(Z_1) = R_0$. Ponieważ w fali $k + 1$ liczba podatnych graczy wynosi co najwyżej $n - 1$, warunkowa wartość oczekiwana liczby nowych zakażeń wywołanych przez Z_k agentów spełnia:

$$\mathbb{E}(Z_{k+1} \mid Z_k) \leq Z_k \cdot (n - 1)p_{\text{trans}} = Z_k R_0. \quad (*)$$

Przypomnijmy, że $R_0 = (n - 1)p_{\text{trans}}$ (Lemat 4) zostało zdefiniowane jako oczekiwana liczba bezpośrednich zakażeń wywołanych przez *pojedynczego* zarażonego agenta w populacji, w której wszyscy pozostali $n - 1$ gracze są podatni. W fali $k + 1$ mamy do czynienia z Z_k zarażonymi agentami jednocześnie, jednak pula podatnych do zarażenia graczy jest wtedy nie większa niż $n - 1$ (może być mniejsza, jeśli część graczy zdążyła się już zarazić lub wyzdrowieć we wcześniejszych falach). Ponieważ oczekiwana liczba zakażeń wywołanych przez pojedynczego zarażonego agenta przy pełnej puli $n - 1$ podatnych wynosi dokładnie R_0 , z liniowości wartości oczekiwanej oczekiwana liczba zakażeń wywołanych łącznie przez Z_k agentów wynosi co najwyżej $Z_k R_0$, skąd nierówność (*). Biorąc bezwarunkową wartość oczekiwaną po obu stronach, z prawa całkowitej wartości oczekiwanej otrzymujemy $\mathbb{E}(Z_{k+1}) \leq \mathbb{E}(Z_k) R_0$. Stąd przez indukcję $\mathbb{E}(Z_k) \leq R_0^k$.

Z liniowości wartości oczekiwanej całkowity oczekiwany rozmiar epidemii wynosi:

$$\mathbb{E}(X^n) = \sum_{t=0}^{\infty} \mathbb{E}(Z_t) \leq 1 + R_0 + R_0^2 + \dots = \frac{1}{1 - R_0}.$$

Otrzymujemy zatem górne ograniczenie na ryzyko indywidualne:

$$\pi_n(R_0) \leq \frac{\frac{1}{1-R_0} - 1}{n-1} = \frac{R_0}{(1-R_0)(n-1)}.$$

Przechodząc z granicą przy $n \rightarrow \infty$ dostajemy $\pi_\infty(R_0) = 0$. □

Twierdzenie 4.2. *Przy oznaczeniach z poprzedniego twierdzenia $\pi_\infty(1) = 0$.*

Dowód. Niech $p_k = \mathbb{P}(X^n \geq k)$. Z podstawowych własności wartości oczekiwanej wiemy, że

$$\mathbb{E}(X^n) = \sum_{k=1}^n p_k. \quad (*)$$

Ponumerujmy zachorowanych graczy chronologicznie $1, 2, \dots, X^n$. Przed k -tą osobą zachorowało $k-1$ graczy, więc w populacji pozostało co najwyżej $n-k$ podatnych agentów. Niech Z_k oznacza liczbę graczy zarażonych bezpośrednio przez osobę k -tą. Wówczas

$$\mathbb{E}(Z_k \mid \text{osoba } k\text{-ta zachorowała}) \leq (n-k)p_{\text{trans}} = \frac{n-k}{n-1} = 1 - \frac{k-1}{n-1}.$$

Wszystkich zachorowanych podczas przebiegu epidemii jest X^n , a więc zarażeń nastąpi $X^n - 1$. Korzystając z równości

$$X^n - 1 = \sum_{k=1}^n Z_k \cdot \mathbf{1}_{\{\text{osoba } k \text{ zachorowała}\}} \quad (S)$$

i liniowości wartości oczekiwanej dostajemy

$$\mathbb{E}[X^n - 1] = \sum_{k=1}^n \mathbb{E}[Z_k \cdot \mathbf{1}_{\{\text{osoba } k \text{ zachorowała}\}}] \leq \sum_{k=1}^n \left(1 - \frac{k-1}{n-1}\right) p_k = \sum_{k=1}^n p_k - \sum_{k=1}^n \frac{k-1}{n-1} p_k.$$

Powyższa równość (S) wymaga uzasadnienia. Ponumerujmy zarażonych chronologicznie; jeśli w danym kroku symulacji podatny węzeł v posiada więcej niż jednego zarażonego sąsiada, przypisujemy zarażenie v dokładnie jednemu z nich (rozstrzygnięcie tej niejednoznaczności nie wpływa na rozkład X^n , a jedynie na etykietowanie, kto *jest odpowiedzialny* za zakażenie). Przy takiej konwencji każdy zarażony gracz $v \neq$ pacjent zero posiada dokładnie jednego przypisanego infektora $k(v) \in \{1, \dots, X^n\}$, a więc zbiory

$$A_k = \{v : k(v) = k\}, \quad k = 1, \dots, X^n$$

są parami rozłączne i ich suma daje wszystkich zarażonych z wyjątkiem pacjenta zero. Ponieważ $Z_k = |A_k|$, otrzymujemy

$$X^n - 1 = \sum_{k=1}^{X^n} Z_k = \sum_{k=1}^n Z_k \cdot \mathbf{1}_{\{\text{osoba } k \text{ zachorowała}\}},$$

gdzie druga równość wynika z faktu, że dla $k > X^n$ agent k nie istnieje (a formalnie: $\mathbf{1}_{\{\cdot\}} = 0$), więc odpowiedni składnik sumy znika.

Korzystając z (*) i redukując sumę $\sum p_k$ po obu stronach, otrzymujemy

$$\sum_{k=1}^n (k-1)p_k \leq n-1. \quad (**)$$

Niech $M = \sqrt{n-1}$. Dzielimy sumę z (*) na dwie części, rozbijając indeksy w punkcie $\lceil M \rceil$:

$$\mathbb{E}[X^n] = \sum_{k=1}^{\lceil M \rceil} p_k + \sum_{k=\lceil M \rceil+1}^n p_k.$$

W pierwszej sumie stosujemy podstawowe oszacowanie $p_k \leq 1$:

$$\sum_{k=1}^{\lceil M \rceil} p_k \leq \lceil M \rceil \leq M + 1.$$

Dla drugiej sumy zauważmy, że dla każdego $k \geq \lceil M \rceil + 1$ zachodzi $k - 1 \geq \lceil M \rceil \geq M$, a więc

$$1 \leq \frac{k-1}{M}.$$

Stąd

$$\sum_{k=\lceil M \rceil+1}^n p_k \leq \frac{1}{M} \sum_{k=\lceil M \rceil+1}^n (k-1)p_k \leq \frac{1}{M} \sum_{k=1}^n (k-1)p_k \leq \frac{n-1}{M},$$

przy czym ostatnia nierówność wynika bezpośrednio z (**).

Łącząc oba oszacowania i podstawiając $M = \sqrt{n-1}$:

$$\mathbb{E}[X^n] \leq (M+1) + \frac{n-1}{M} = \sqrt{n-1} + 1 + \frac{n-1}{\sqrt{n-1}} = 2\sqrt{n-1} + 1,$$

a więc ostatecznie

$$\pi_n(1) = \frac{\mathbb{E}[X^n] - 1}{n-1} \leq \frac{2\sqrt{n-1}}{n-1} = \frac{2}{\sqrt{n-1}} \xrightarrow{n \rightarrow \infty} 0.$$

□

5 Numeryczne przybliżanie punktów równowagi

Zastosowanie przekształcenia najlepszej odpowiedzi (Definicja 2.6) wyznacza bezpośrednią regułę decyzyjną agentów. Operacja ta wymaga jednak znajomości wartości $\pi_i(\mathbf{a})$, określającej prawdopodobieństwo zakażenia i -tego agenta przy ustalonym profilu strategii $\mathbf{a}$. Ze względu na analityczną nieobliczalność złożonych procesów sieciowych, wartość tego prawdopodobieństwa estymowana jest numerycznie za pomocą stochastycznych symulacji Monte Carlo. Procedura ta polega na wykonaniu serii M niezależnych eksperymentów na ustalonej topologii grafu przy stałym wektorze decyzji populacji $\mathbf{a}$. Oczekiwana wartość prawdopodobieństwa zakażenia aproksymowana jest poprzez częstość empiryczną, zdefiniowaną jako iloraz liczby prób, w których dany agent uległ infekcji, do całkowitej liczby zrealizowanych symulacji.

5.1 Numeryczna weryfikacja profili równowagi

W celu weryfikacji, czy zadany profil strategii $\mathbf{a} \in \{0, 1\}^N$ stanowi równowagę Nasha, konieczne jest wyznaczenie wektora prawdopodobieństw zakażenia $\boldsymbol{\pi}(\mathbf{a})$. Dla ogólnych topologii sieciowych analityczne wyznaczenie wartości π_i staje się niewykonalne obliczeniowo, co wymusza zastosowanie estymacji metodą Monte Carlo.

Dla każdego agenta $i \in V$ (gdzie $N = |V|$):

1. Ustalamy hipotezę braku szczepienia $a_i = 0$, pozostawiając strategię reszty populacji $\mathbf{a}_{-i}$ bez zmian.
2. Przeprowadzamy M niezależnych symulacji przebiegu epidemii SIR, gdzie w każdej próbie pacjent zero jest losowany jednostajnie spośród niezaszczepionych graczy $S = \{j \in V \mid a_j = 0\}$.
3. Rejestrujemy liczbę symulacji M_i , w których i -ty agent uległ infekcji.

Estymator punktowy ryzyka zakażenia i -tego agenta definiujemy jako częstość empiryczną:

$$\hat{\pi}_i(0, \mathbf{a}_{-i}) = \frac{M_i}{M}.$$

Procedurę tę powtarzamy iteracyjnie dla wszystkich N graczy, otrzymując wektor estymowanych prawdopodobieństw $\hat{\boldsymbol{\pi}} = (\hat{\pi}_1, \dots, \hat{\pi}_N)$. Na jego podstawie weryfikujemy warunek najlepszej odpowiedzi $a_i = BR_i(\mathbf{a}_{-i})$ dla każdego gracza $i \in V$. Implementację algorytmu estymacyjnego można znaleźć w Listingu 7.

Dysponując algorytmem estymacji Monte Carlo, jesteśmy w stanie z określoną dokładnością stochastyczną weryfikować, czy zadany profil strategii $\mathbf{a} \in \{0, 1\}^N$ stanowi czystą równowagę Nasha.

Procedura weryfikacji sprowadza się do wyznaczenia wyestymowanego wektora ryzyka zakażenia $\hat{\boldsymbol{\pi}}$ i sprawdzenia, czy dla każdego agenta $i \in V$ zachodzi warunek najlepszej odpowiedzi:

$$a_i = BR_i(\mathbf{a}_{-i}) = \begin{cases} 1, & \text{jeśli } \hat{\pi}_i(0, \mathbf{a}_{-i}) > r, \\ 0, & \text{jeśli } \hat{\pi}_i(0, \mathbf{a}_{-i}) \leq r. \end{cases}$$

Profil strategii $\mathbf{a} \in \{0, 1\}^N$ uznajemy za czystą równowagę Nasha wtedy i tylko wtedy, gdy żaden z agentów nie odnosi korzyści z jednostronnej zmiany decyzji, co odpowiada spełnieniu warunku $a_i = BR_i(\mathbf{a}_{-i})$ dla każdego $i \in \{1, \dots, N\}$. Precyzja stochastyczna przeprowadzonego testu zależy bezpośrednio od liczby symulacji M , zgodnie z asymptotycznymi właściwościami estymatora Monte Carlo. Algorytm weryfikujący warunek równowagi został zaimplementowany w Listingu 8, natomiast skrypt walidujący analityczne hipotezy na zdefiniowanych topologiach przedstawiono w Listingu 9. Otrzymane wyniki konsolowe zestawiono poniżej:

```

1 =====
2 TEST: 1. Losowy graf spójny (pełne szczepienie)
3 =====
4 Wynik numeryczny: RÓWNOWAGA NASHA
5
6 =====
7 TEST: 2. Gwiazda K_{1,3} (hub R, liście S)
8 =====
9 Wynik numeryczny: RÓWNOWAGA NASHA
10
11 =====
12 TEST: 3. Diament K_4 \ {e} (stopień 3 R, stopień 2 S)
13 =====

```

```
14 Wynik numeryczny: RÓWNOWAGA NASHA
15
16 =====
17 TEST: 4. Cykl C_4 z 3 liśćmi (cykl R, liście S)
18 =====
19 Wynik numeryczny: BRAK RÓWNOWAGI
20 Wykryte odstępstwa (gracz: BR_i): {1: 0, 2: 0, 3: 0, 4: 0}
```

Listing 2: Wyniki walidacji numerycznej wygenerowane przez program

6 Fragmenty kodu

W poniższym rozdziale przedstawiono kluczowe fragmenty kodu implementującego omawiane modele i symulacje. Obliczenia zrealizowano w środowisku języka Python [3], opierając się na kilku dedykowanych pakietach. Do tworzenia i analizy struktur sieciowych, w szczególności do generowania grafów losowych w modelach Erdősa-Rényiego (ER) oraz Albert-Barabásiego (AB), posłużyła biblioteka networkx [4]. Wizualizację otrzymanych wyników oraz rysowanie badanych grafów przeprowadzono za pomocą narzędzia matplotlib [5]. Z kolei za generowanie rozkładów probabilistycznych, niezbędnych do prawidłowego modelowania procesów stochastycznych w układzie, odpowiadał wbudowany moduł random.

6.1 Sieć społeczna na grafie oraz symulacja epidemii

Poniżej kod programu generujący grafy losowe pokazane w Rysunku 1.

```
1 import networkx as nx
2 import matplotlib.pyplot as plt
3
4 # Układ 2 wiersze x 3 kolumny (Góra: ER, Dol: BA)
5 fig, axes = plt.subplots(2, 3, figsize=(18, 10))
6
7 # -----
8 # 1. GRAFY ERDOSA-RENYIEGO (ER) - Różne parametry (N, p)
9 # -----
10 er_params = [
11     {"N": 30, "p": 0.08}, # Mała, rzadka sieć
12     {"N": 60, "p": 0.15}, # Średnia sieć
13     {"N": 90, "p": 0.25}  # Duża, gęsta sieć
14 ]
15
16 for i, params in enumerate(er_params):
17     N, p = params["N"], params["p"]
18     G_er = nx.erdos_renyi_graph(n=N, p=p, seed=42)
19     avg_k = p * (N - 1)
20
21     pos = nx.spring_layout(G_er, seed=42)
22     sizes = [d * 25 + 40 for _, d in G_er.degree()]
23
24     ax = axes[0, i]
25     nx.draw_networkx_nodes(G_er, pos, ax=ax, node_size=sizes, node_color='skyblue',
26                             alpha=0.85)
27     nx.draw_networkx_edges(G_er, pos, ax=ax, alpha=0.3)
28
29     ax.axis('off')
30
31 # -----
32 # 2. GRAFY BARABASIEGO-ALBERTA (BA) - Różne parametry (N, m)
33 # -----
34 ba_params = [
35     {"N": 30, "m": 1}, # Minimalne połączenia (struktura drzewiasta)
36     {"N": 60, "m": 2}, # Standardowa sieć z hubami
37     {"N": 90, "m": 4}  # Duża sieć z silnymi, gęstymi hubami
38 ]
39
40 for i, params in enumerate(ba_params):
41     N, m = params["N"], params["m"]
42     G_ba = nx.barabasi_albert_graph(n=N, m=m, seed=42)
43     avg_k = 2 * m
44
45     pos = nx.spring_layout(G_ba, seed=42)
```

```

45     sizes = [d * 20 + 40 for _, d in G_ba.degree()]
46
47     ax = axes[1, i]
48     nx.draw_networkx_nodes(G_ba, pos, ax=ax, node_size=sizes, node_color='salmon',
49                             alpha=0.85)
50     nx.draw_networkx_edges(G_ba, pos, ax=ax, alpha=0.3)
51
52     ax.axis('off')
53 plt.tight_layout()
54 plt.show()

```

Listing 3: Skrypt generujący grafy z Rysunku 1

Poniżej skrypt generujący pewien graf Erdős-Rényiego, losujący profil strategii (czy szczepią się czy nie) ze współczynnikiem zaszczepienia v_{rate} . Pacjent zero wybierany jest losowo. W linijce 33 rysowany jest graf przedstawiony na Rysunku 2.

```

1  import random
2  import matplotlib.pyplot as plt
3  import networkx as nx
4
5
6
7  def initialize_epidemic_graph(N=15, p=0.2, v_rate=0.3, seed=42):
8      random.seed(seed)
9
10     # 1. Generowanie grafu
11     G = nx.erdos_renyi_graph(n=N, p=p, seed=seed)
12
13     # 2. Losowanie strategii (S lub R) dla każdego wierzchołka
14     # v_rate = prawdopodobieństwo, że agent wybierze zaszczepienie (R)
15     for node in G.nodes():
16         G.nodes[node]["state"] = "R" if random.random() < v_rate else "S"
17
18     # 3. Losowanie pacjenta zero ('I') spośród niezaszczepionych ('S')
19     susceptible_nodes = [
20         n for n, attr in G.nodes(data=True) if attr["state"] == "S"
21     ]
22
23     if susceptible_nodes:
24         patient_zero = random.choice(susceptible_nodes)
25     else:
26         patient_zero = random.choice(list(G.nodes()))
27
28     G.nodes[patient_zero]["state"] = "I"
29
30     return G, patient_zero
31
32
33  def draw_graph(G):
34     color_map = {"S": "skyblue", "I": "salmon", "R": "lightgreen"}
35     node_colors = [color_map[G.nodes[n]["state"]] for n in G.nodes()]
36
37     plt.figure(figsize=(8, 6))
38     pos = nx.spring_layout(G, seed=42)
39
40     nx.draw_networkx_nodes(
41         G, pos, node_color=node_colors, node_size=600, edgcolors="black"
42     )

```

```

43     nx.draw_networkx_edges(G, pos, alpha=0.4)
44     nx.draw_networkx_labels(
45         G, pos, font_size=10, font_weight="bold", font_color="black"
46     )
47
48     # Legenda
49     for state, color in color_map.items():
50         plt.scatter([], [], c=color, label=state, edgecolors="black", s=100)
51
52     plt.legend(title="Stan")
53     plt.axis("off")
54     plt.tight_layout()
55     plt.show()
56
57
58 # Uruchomienie
59 G, p0 = initialize_epidemic_graph(N=30, p=0.2, v_rate=0.3)
60 print(f"Pacjent zero to węzeł nr: {p0}")
61 draw_graph(G)

```

Listing 4: Skrypt implementujący model SIR na grafie losowym z modelu E-R

Dla wygenerowanego grafu oraz wylosowanego profilu strategii graczy poniższy skrypt przeprowadzi symulację przebiegu epidemii oraz zbierze dane na jej temat.

```

1 def run_sir_simulation(G, beta=1 / 3, gamma=1 / 2, verbose=True):
2     """Przeprowadza symulację SIR na podanym grafie G aż do wygaszenia ognisk
3     zakazen (I = 0).
4
5     - beta: prawdopodobieństwo transmisji przez krawędź w jednym kroku (1/3)
6     - gamma: prawdopodobieństwo wyzdrowienia w jednym kroku (1/2)
7     """
8     t = 0
9
10    if verbose:
11        print("=== Start Symulacji SIR ===")
12
13    while True:
14        # Wyszukujemy węzły aktualnie chorujące
15        infected = [n for n in G if G.nodes[n]["state"] == "I"]
16
17        # Warunek stopu: brak chorujących (I = 0)
18        if not infected:
19            if verbose:
20                print(f"\n[Koniec] Epidemia wygasła w kroku t = {t}.")
21            break
22
23        t += 1
24        newly_infected = set()
25        newly_recovered = set()
26
27        # 1. Faza transmisji (S -> I)
28        for u in infected:
29            for v in G.neighbors(u):
30                if G.nodes[v]["state"] == "S":
31                    if random.random() < beta:
32                        newly_infected.add(v)
33
34        # 2. Faza wyzdrowienia (I -> R)
35        for u in infected:

```

```

35         if random.random() < gamma:
36             newly_recovered.add(u)
37
38         # 3. Synchroniczna aktualizacja stanów węzłów po kroku t
39         for v in newly_infected:
40             G.nodes[v]["state"] = "I"
41
42         for u in newly_recovered:
43             G.nodes[u]["state"] = "R"
44
45         # Raportowanie stanu sieci
46         if verbose:
47             s_cnt = sum(1 for n in G if G.nodes[n]["state"] == "S")
48             i_cnt = sum(1 for n in G if G.nodes[n]["state"] == "I")
49             r_cnt = sum(1 for n in G if G.nodes[n]["state"] == "R")
50             print(
51                 f"Krok t = {t:2d} | S: {s_cnt:2d} | I: {i_cnt:2d} | R: {r_cnt:2d} |
52                 "
53                 f"Nowe infekcje: {len(newly_infected)} | Wyzdrowieli: {len(
54                     newly_recovered)}"
55             )
56
57     return G, t

```

Listing 5: Skrypt implementujący symulację epidemii wedle modelu SIR na grafie losowym

6.2 Zależności między parametrami w grafach pełnych

Poniższa symulacja szacuje indywidualne ryzyko zachorowania niezaszczepionego agenta $\pi(n)$ w grafie pełnym K_n jako funkcję wielkości populacji $n \in [10, 10\,000]$ dla różnych reżimów zakaźności patogenu R_0 . Model opiera się na dyskretnym procesie epidemii SIR, w którym prawdopodobieństwo transmisji na krawędzi jest skalowane zgodnie z zależnością $p_{\text{trans}} = \frac{R_0}{n-1}$. Wyniki symulacji widoczne są na rysunku 7.

```

1  def simulate_pi_r0_vectorized(n, R_0, num_sims=5000):
2      """
3      Wektorowa symulacja Monte Carlo ryzyka pi(n) w grafie K_n.
4      """
5      if n <= 1:
6          return 0.0
7
8      # Skalowanie prawdopodobieństwa transmisji na krawędzi
9      p_trans = min(R_0 / (n - 1), 1.0)
10
11     # Macierz stanu zakazen dla num_sims niezależnych prób jednocześnie
12     infected = np.zeros((num_sims, n), dtype=bool)
13     infected[:, 0] = True # Pacjent Zero ma indeks 0
14     newly_infected = infected.copy()
15
16     while np.any(newly_infected):
17         # Liczba nowych ognisk zakażenia w każdej symulacji
18         num_new = newly_infected.sum(axis=1, keepdims=True)
19
20         # Prawdopodobieństwo uniknięcia infekcji ze wszystkich nowych źródeł
21         prob_escape = (1.0 - p_trans) ** num_new
22
23         susceptible = ~infected
24         rand_vals = np.random.rand(num_sims, n)
25
26         # Wyznaczenie węzłów zakażonych w kolejnej fali

```

```

27     next_infected = susceptible & (rand_vals >= probab_escape)
28     infected |= next_infected
29     newly_infected = next_infected
30
31     # Średnia całkowita wielkość epidemii  $E[X]$  przeskalowana do indywidualnego
ryzyka
32     avg_total = np.mean(infected.sum(axis=1))
33     return (avg_total - 1) / (n - 1)

```

Listing 6: Estymacja jednostkowego ryzyka zarażenia na grafie pełnym metodą Monte Carlo

6.3 Implementacja racjonalnego myślenia agentów

Fragmencie kodu odpowiadający za oszacowanie wektora prawdopodobieństw na zakażenie chorobą metodą Monte Carlo.

```

1 def estimate_pi(G, strategy_profile, beta=1/3, gamma=1/2, M=None):
2     """
3     Estymuje wektor prawdopodobieństw zakażenia pi_i(0, a_{-i}) metoda Monte Carlo.
4
5     Parameters:
6     - G: nx.Graph, topologia sieci
7     - strategy_profile: dict {node: 0 lub 1}, gdzie 1 = zaszczepiony, 0 =
      niezaszczepiony
8     - beta, gamma: parametry epidemii
9     - M: liczba symulacji na agenta (domyślnie N * 100)
10
11     Returns:
12     - pi_hat: dict {node: probab_infection}, wyestymowany wektor pi
13     """
14     N = G.number_of_nodes()
15     if M is None:
16         M = N * 100
17
18     pi_hat = {}
19
20     for i in G.nodes():
21         # 1. Tworzymy profil (0, a_{-i}) -- wymuszamy brak szczepienia agenta i
22         test_profile = strategy_profile.copy()
23         test_profile[i] = 0
24
25         # Zbiór niezaszczepionych graczy (w tym agent i)
26         S_nodes = [node for node, state in test_profile.items() if state == 0]
27
28         infections_count = 0
29
30         # 2. M niezależnych symulacji Monte Carlo dla gracza i
31         for _ in range(M):
32             H = G.copy()
33
34             # Ustawienie stanów początkowych S / R
35             for node in H.nodes():
36                 H.nodes[node]["state"] = "R" if test_profile[node] == 1 else "S"
37
38             # Losowanie pacjenta zero spośród niezaszczepionych (S)
39             patient_zero = random.choice(S_nodes)
40             H.nodes[patient_zero]["state"] = "I"
41
42             # Przeprowadzenie symulacji SIR (bez wypisywania komunikatów)

```

```

43     run_sir_simulation(H, beta=beta, gamma=gamma, verbose=False)
44
45     # 3. Jesli agent i zmienil stan z 'S' na 'I' lub 'R', ulegl zakazeniu
46     if H.nodes[i]["state"] != "S":
47         infections_count += 1
48
49     # Częstość empiryczna M_i / M
50     pi_hat[i] = infections_count / M
51
52     return pi_hat

```

Listing 7: Estymacja wektora prawdopodobieństw zakażenia π metodą Monte Carlo

```

1  def is_nash_equilibrium(G, strategy_profile, r=0.5, beta=1 / 3, gamma=1 / 2, M=None
    , tol=1e-2, verbose=True):
2      pi_hat = estimate_pi(G, strategy_profile, beta=beta, gamma=gamma, M=M)
3
4      is_ne = True
5      deviations = {}
6
7      for node in G.nodes():
8          current_action = strategy_profile[node]
9          pi_i = pi_hat[node]
10
11         # Uwzględnienie tolerancji dla wartosci na granicy r
12         if pi_i > r + tol:
13             best_response = 1
14         elif pi_i < r - tol:
15             best_response = 0
16         else:
17             best_response = current_action # Brak jednoznacznego bodzca do zmiany
18             (obojetnosc)
19
20         if current_action != best_response:
21             is_ne = False
22             deviations[node] = best_response
23
24     return is_ne, deviations

```

Listing 8: Weryfikacja warunku rownowagi Nasha z uwzględnieniem tolerancji numerycznej

Kluczowym elementem funkcji `is_nash_equilibrium` jest wprowadzenie marginesu tolerancji numerycznej `tol`. W sytuacjach, gdy teoretyczne ryzyko zakażenia danego agenta leży dokładnie na granicy decyzyjnej ($\pi_i = r$), empiryczny estymator Monte Carlo $\hat{\pi}_i$ podlega naturalnym fluktuacjom stochastycznym wynikającym ze skończonej próby M . Bez zdefiniowanego przedziału obojętności nawet znikomy szum próbkowania mógłby sprawić, że wyestymowana wartość minimalnie przekroczy próg r (np. $\hat{\pi}_i = 0.501$ dla $r = 0.5$). Prowadziłoby to do błędnego zakwalifikowania agenta jako niestabilnego i sztucznego wykrycia odstępstwa (ang. *false positive*). Zastosowanie strefy $[r - \text{tol}, r + \text{tol}]$ zapewnia odporność algorytmu na błędy estymacji i umożliwia poprawną identyfikację słabych równowag Nasha.

```

1  # 1. Przykład 1: Losowy spójny graf z pełnym szczepieniem a = (1, ..., 1)
2  while True:
3      G1 = nx.erdos_renyi_graph(n=8, p=0.4, seed=42)
4      if nx.is_connected(G1):
5          break
6  profile1 = {n: 1 for n in G1.nodes()}
7
8  # 2. Przykład 2: Gwiazda K_{1,3} (Hub zaszczepiony, liście niezaszczepione)
9  G2 = nx.star_graph(3) # Węzeł 0 to hub, węzły 1, 2, 3 to liście

```

```

10 profile2 = {0: 1, 1: 0, 2: 0, 3: 0}
11
12 # 3. Przykład 3: Diament K_4 \ {e} (Węzły o stopniu 3 zaszczepione, o stopniu 2 nie
13 )
14 G3 = nx.Graph([(0, 1), (0, 2), (0, 3), (1, 2), (1, 3)])
15 profile3 = {0: 1, 1: 1, 2: 0, 3: 0}
16
17 # 4. Przykład 4: Cykl C_4 z 3 liśćmi (Profile a = (1,1,1,1,0,0,0))
18 G4 = nx.Graph([(1, 2), (2, 3), (3, 4), (4, 1), (1, 5), (2, 6), (3, 7)])
19 profile4 = {1: 1, 2: 1, 3: 1, 4: 1, 5: 0, 6: 0, 7: 0}
20
21 # Zestawienie przypadków testowych
22 examples = [
23     ("1. Losowy graf spójny (pełne szczepienie)", G1, profile1),
24     ("2. Gwiazda K_{1,3} (hub R, liście S)", G2, profile2),
25     ("3. Diament K_4 \ {e} (stopień 3 R, stopień 2 S)", G3, profile3),
26     ("4. Cykl C_4 z 3 liśćmi (cykl R, liście S)", G4, profile4),
27 ]
28
29 # Weryfikacja hipotez analitycznych
30 for name, G, profile in examples:
31     print(f"\n=====")
32     print(f"TEST: {name}")
33     print(f"=====")
34
35     is_ne, dev = is_nash_equilibrium(
36         G,
37         profile,
38         r=0.5,
39         beta=1 / 2,
40         gamma=1 / 2,
41         M=2000, # Liczba prób dla wysokiej dokładności
42         verbose=False,
43     )
44
45     verdict = "RÓWNOWAGA NASHA" if is_ne else "BRAK RÓWNOWAGI"
46     print(f"Wynik numeryczny: {verdict}")
47
48     if not is_ne:
49         print(f"Wykryte odstępstwa (gracz: BR_i): {dev}")

```

Listing 9: Skrypt weryfikujący równowagi Nasha dla testowych topologii grafowych

Bibliografia

- [1] Bauch, C. T., & Earn, D. J. D. (2004). Vaccination and the theory of games. *Proceedings of the National Academy of Sciences*, 101(36), 13391–13394.
- [2] Koutsoupias, E., & Papadimitriou, C. H. (1999). Worst-case equilibria. W: *Proceedings of the 16th Annual Symposium on Theoretical Aspects of Computer Science (STACS)*, Lecture Notes in Computer Science, vol. 1563, s. 404–413. Springer.
- [3] Python Core Team (2023). Python: A dynamic, open source programming language. *Python Software Foundation*. Dostępne pod adresem: <https://www.python.org/>
- [4] Hagberg, A. A., Schult, D. A., & Swart, P. J. (2008). Exploring network structure, dynamics, and function using NetworkX. *Proceedings of the 7th Python in Science Conference*, 11–15.
- [5] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.